

INSTITUTO TECNOLÓGICO Y DE ESTUDIOS
SUPERIORES DE MONTERREY

Proyecto MiBici: propuesta y base reproducible

Alan Arturo Hernández Chichitz – A01062611
Edgar González Paz – A01840158
Isaac González Trejo – A01274193
Mario Alberto González Pérez – A01840153

Operaciones de aprendizaje automático (TC5061.10)
18/10/2026

MACHINE LEARNING CANVAS

Designed for: MiBici | Designed by: Equipo 37 | Date: 18/10/2026 | Iteration: 1

PREDICTION TASK

What is the type of task?
Which entity are predictions made on?
What are the possible outcomes to predict?
When are outcomes observed?

P1 – Regresión: viajes que iniciarán en cada estación durante el día siguiente (entidad estación × día; horizonte t+1 día).

P2.1 - clasificación multiclase: {normal,riesgo de vaciado, riesgo de llenado}, 10% (vaciado) o ≥ 90% (llenado) en algún momento de t, t+2h.

P2 (E) - Clasificación supervisada multiclase. Entidad: estación MiBici por hora observada. Objetivo: clasificar el flujo de la siguiente hora como bajo, medio o alto. El objetivo se observa en la siguiente hora consecutiva con registros; no se predicen horas sin viajes

P3 – Clustering: grupos de estaciones con patrones de uso similares (perfil horario/semanal) y su ubicación.

Los resultados se observan con los viajes registrados: al cierre de cada día para P1..

DECISIONS

How are predictions turned into actionable recommendations or decisions for the end-user? (Mention parameters of the process / application for this.)

P1: identificar las estaciones con mayor demanda esperada para el día siguiente y apoyar la planificación de la redistribución de bicicletas y del personal.

P2.1:.Cada hora se proporciona un ranking de estaciones por probabilidad de riesgo, con la acción sugerida (llevar o retirar bicis). El equipo visita las top-k(k = capacidad de visitas porhora de los camiones).

P2 (E) - Usar la clase prevista como alerta de apoyo para priorizar la revisión de estaciones con posible desequilibrio. Umbrales actuales: bajo (flujo neto entre −3 y 3), medio (±4 a ±5) y alto (|flujo neto| ≥ 6). Requiere validación operativa antes de tomar acciones; no automatizar redistribución solo con esta predicción.

P3: priorizar zonas para nuevas estaciones o ampliar capacidad; estrategias por tipo de estación (residencial, laboral/escolar, mixta/recreativa).

VALUE PROPOSITION

Who is the end beneficiary, and what specific pain points are addressed?
How will the ML solution integrate with their workflow, and through which user interfaces?

Usuarios: operador de MiBici (planeación de flota), equipo de rebalanceo y área de planeación urbana/expansión.

Problema: la demanda es desigual por estación, hora y día; hay estaciones sin bicicletas para iniciar viajes o sin anclajes para terminarlos, y la expansión se decide sin evidencia de patrones de uso.

Valor: P1 anticipa la demanda para dimensionar la flota; P2 alerta con anticipación el riesgo de vacío/lleno para priorizar el rebalanceo; P3 segmenta estaciones en un mapa para orientar la expansión.

Integración: reporte diario de demanda esperada por estación, lista priorizada de estaciones en riesgo y mapa de grupos de estaciones.

P2 (E) - Beneficiarios potenciales: equipo operativo de MiBici y usuarios. La solución busca anticipar estaciones con desequilibrio de llegadas y salidas para apoyar la planificación. La integración prevista sería un tablero operativo con estación, hora, clase prevista y métricas; aún no está desplegada.

DATA COLLECTION

How is the initial set of entities and outcomes sourced (e.g., database extracts, API pulls, manual labeling)?
What strategies are in place to update data continuously while controlling cost and maintaining freshness?

Ingesta reproducible con un solo comando (módulo dataset): descarga los meses del rango elegido y la nomenclatura, normaliza columnas, codificación y fechas, y guarda en Parquet.
Versionado: manifiesto en Git con número de registros y hash SHA-256 por archivo; la versión se registra en MLflow.
Etiquetas derivadas de los propios viajes (conteos y balance neto), sin etiquetado manual. Actualización mensual al publicarse nuevos archivos.
Partición temporal train / validación / test por meses consecutivos, sin barajar, para no usar información del futuro.

DATA SOURCES

Where can we get data on entities and observed outcomes? (Mention internal and external database tables or API methods.)

Portal de Datos Abiertos de MiBici (Sistema de Bicicleta Pública del AMG): Viajes mensuales datos_abiertos_AAAA_MM.csv (desde dic-2014): id de viaje, usuario, inicio y fin (fecha y hora), estación de origen y destino.
Nomenclatura de estaciones nomenclatura_2026_09.csv: id, nombre, latitud, longitud y capacidad.
Externa opcional: calendario de días festivos.
Se respetan las condiciones de uso de MiBici; los datos personales (id de usuario, género, año de nacimiento) se excluyen o solo se usan agregados.

IMPACT SIMULATION

What are the cost/gain values for (in)correct decisions?
Which data is used to simulate pre-deployment impact?
What are the criteria for deployment?
Are there fairness constraints?

Backtesting temporal sobre meses de prueba no vistos, comparando contra el baseline.
Costos: en P1 subestimar deja estaciones vacías y sobreestimar deja bicicletas ociosas; el error del modelo se compara contra el baseline histórico y se analiza en estaciones de alta y baja demanda (una simulación económica requeriría datos operativos adicionales).
Criterio de despliegue: P1 con val_mae y val_rmse menores al baseline semanal; P3 con buen silhouette y grupos interpretables para planeación.
Equidad y privacidad: no se usan género ni edad de los usuarios; se revisa que el desempeño no sea mucho peor en estaciones periféricas o de baja demanda.

P2.1 - Costo FN: viajes perdidos en la estación que falla.
Costo FP:
una visita de camión innecesaria (~20 min de ruta).
Simulación: sobre el periodo de prueba, cubrir cada hora las top-k del modelo vs. el baseline de persistencia.
Criterio de despliegue: superar al baseline en recall@k y en PR-AUC de ambas clases de riesgo.
Equidad: revisar recall por zona, para no atender solo estaciones principales.

P2 (E) - La evaluación disponible usa F1 macro y balanced accuracy, además de precisión y recall de la clase alta. En test: F1 macro ≈ 0.370, balanced accuracy ≈ 0.505, F1 alto ≈ 0.197, precisión alta ≈ 0.118 y recall alto ≈ 0.585. Costos monetarios de falsas alarmas y casos no detectados aún no están definidos; deben estimarse con Operaciones antes de desplegar.

MAKING PREDICTIONS

Are predictions made in batch or in real time?
How frequently?
How much time is available for this (including featurization and decisions)?
Which computational resources are used?

Predicción por lotes (batch), no en tiempo real.
P1: proceso diario por lotes que estima los viajes del día siguiente en cada estación.

P2.1 - Batch, cada hora, antes de despachar rutas.
Poco poder computacional necesario.

P2 (E) - Prototipo ejecutado en batch sobre datos históricos en una notebook Python. No es un servicio en tiempo real ni está desplegado. La frecuencia futura dependerá de la disponibilidad de datos y del proceso operativo; objetivo inicial a evaluar: actualización horaria.
Entrenamiento/evaluación con scikit-learn y seguimiento de experimentos con MLflow.

P3: se recalcula mensual o trimestralmente al publicarse nuevos datos.
En el curso las predicciones se generan offline sobre los meses de prueba (MiBici publica datos mensuales). Recursos: una laptop o VM con Python, pandas y scikit-learn es suficiente.

BUILDING MODELS

How many models are needed in production?
When should they be updated?
How much time is available for this (including featurization and analysis)?
Which computation resources are used?

Tres modelos en producción, uno por pregunta, registrados en un experimento de MLflow (mibici-equipo37).
P1: baseline = viajes del mismo día de la semana anterior (lag 7). Candidato: Random Forest Regressor. Métricas: val_mae, val_rmse, con validación y prueba cronológicas.

P2.1: Baseline 1, persistencia Clasifica según la ocupación estimada actua. Los umbrales a y b se ajustan en validación Baseline 2, perfil histórico. Es la frecuencia de cada clase por estación × día de la semana × hora en entrenamiento.
Candidato, gradient boosting multiclase (HistGradientBoostingClassifier). Usa 23 features (estado actual, demanda reciente y estacional, historial de riesgo, calendario y estación)

P3: baseline = K-Means con k fijo.
Candidatos: K-Means con k por silhouette/codo y clustering jerárquico.
Resultado actual: k = 3 (silueta 0.125, ARI vs. Ward 0.71). Métricas: silhouette y Davies-Bouldin.
Reentrenamiento mensual con cada nuevo archivo; entrenamiento de minutos en CPU. Semilla, rutas y fechas centralizadas en config.

P2 (E) - Se compararon Regresión Logística, Random Forest y HistGradientBoosting. Se seleccionó provisionalmente RandomForest_v1 por F1 macro en validación, usando balanced accuracy como métrica complementaria. La ejecución final de test quedó registrada en MLflow junto con métricas y artefactos. Reentrenar cuando haya suficiente dato nuevo o se detecte degradación; la cadencia aún debe definirse.

FEATURES

What representations are used for entities at prediction time?
What aggregations or transformations are applied to raw data sources?

Funciones reutilizables en el módulo features, calculadas solo con información anterior al momento de la predicción:
Temporales: hora, día de la semana, fin de semana, mes, día festivo.
P1 (diario): estación, día de la semana, mes, fin de semana, viajes del día anterior y de hace 7 días y promedio móvil de 7 días.

P2.1 - Ocupación simulada en t y su tendencia en la última hora.
Lags de salidas y llegadas (1 h, 2 h, 24 h, 168 h) y medias móviles.
Hora, día de la semana, fin de semana, festivo.
Capacidad, coordenadas..
Agregación: viajes → conteos por estación × hora. Estimado de numero de bicicletas al inicio de cada dia por estacion.

P3: perfil horario normalizado de salidas y llegadas (24 h × 2), proporción de uso en fin de semana, duración media y porcentaje de viajes circulares.

P2 (E) - Variables predictoras: día de la semana, mes, hora codificada con seno/coseno, flujo neto anterior, salidas anteriores y llegadas anteriores. Se agregan viajes por estación y hora; el flujo neto se calcula como llegadas menos salidas. Los rezagos solo se usan cuando existe continuidad de una hora para la misma estación.

MONITORING

Which metrics and KPIs are used to track the ML solution's impact once deployed, both for end-users and for the business?
How often should they be reviewed?

Desempeño del modelo: comparar

	predicciones contra los viajes reales del mes siguiente (MAE y RMSE globales y por grupos de estaciones en P1; recall y precisión de las alertas en P2; estabilidad de los grupos en P3). Deriva de datos: cambios en la demanda por estacionalidad, eventos, estaciones nuevas o cambios de capacidad. KPIs de negocio: porcentaje de horas-estación vacías o llenas, viajes no realizados y distancia recorrida en rebalanceo. Revisión mensual al publicarse nuevos datos; si el error supera al baseline se reentrena y se registra un nuevo run en MLflow.		

Version 1.2. Created by Louis Dorard, Ph.D. Licensed under a Creative Commons Attribution-ShareAlike 4.0 International License.
Please keep this mention and the link to ownml.co when sharing.

OWNML.CO