

Tecnológico de Monterrey

Instituto Tecnológico y de Estudios Superiores de Monterrey

Maestría en Inteligencia Artifical Aplicada

TC5061.10 Operaciones de aprendizaje automático

Construye | MLflow Project y tracking avanzado | Colaborativo

Presenta:

Edgar González Paz - A01840158

Isaas González Trejo – A01274193

Alan Arturo Hernández Chichitz - A01062611

Mario Alberto González Pérez - A01840153

Docentes:

Iván Reyes Amezcua (Profesor titular)

Ricardo Valdez Hernández (Profesor tutor)

Yetnalezi Quintas Ruiz (Profesor tutor)

FECHA:

25 de octubre del 2026

MLflow Project y tracking avanzado

1. Alcance, entorno y reproducibilidad

La entrega integra ingesta automatizada, construcción de características, entrenamiento, comparación y registro de modelos para tres preguntas operativas de MiBici. El experimento mibici-equipo37 utiliza MLflow Tracking con backend SQLite y manifiestos de datos identificados mediante SHA-256. Los modelos supervisados mantienen entrenamiento hasta junio de 2025 y validación entre julio y septiembre de 2025; P1 dispone además de evaluación de prueba de octubre a diciembre de 2025. P3 se evalúa mediante métricas internas y estabilidad, sin conjunto de prueba supervisado.

El MLproject define main, ingest, train, search y register, y declara python_env.yaml. El README documenta el servidor local y la ejecución mediante mlflow run. Se comprobó la ejecución desde un clon limpio de main (commit 6a5c9f85d2ce153c1283b9e38595c34bd696e3e0), con Python 3.10 y MLflow 3.17.2: instalación, servidor SQLite, ingesta de 9,177,953 viajes y SHA-256 coincidente. Los tres entrenamientos terminaron correctamente mediante mlflow run; P1 reprodujo las métricas originales, mientras que P2 y P3 se ejecutaron con valores predeterminados distintos de los modelos champion.

```
mlflow server --backend-store-uri sqlite:///mlflow.db --port 5000
export MLFLOW_TRACKING_URI=http://localhost:5000
mlflow run . -e ingest --experiment-name mibici-equipo37 --env-manager local
mlflow run . -e train -P question=p1 -P model=rf --experiment-name mibici-equipo37 --env-manager local
mlflow run . -e train -P question=p2 -P model=hist_gradient_boosting --experiment-name mibici-equipo37 --env-manager local
mlflow run . -e train -P question=p3 -P model=pca_kmeans --experiment-name mibici-equipo37 --env-manager local
```

Advertencia de reproducibilidad: la versión del MLproject compartida declara en train solamente question y model; antes de publicar comandos con -P n_estimators, -P learning_rate o -P n_clusters deben añadirse parámetros compatibles al entry point o documentarse un mecanismo realmente probado. El README todavía contiene marcadores de selección pendiente.

2. P1. Predicción de demanda diaria

Modelo	Árboles / profundidad	MAE validación ↓	RMSE validación ↓	Tiempo (s)
Baseline semanal	—	6.8808	12.2986	N/D
Random Forest	70 / 12	5.5360	9.6445	7.37
Random Forest	70 / 18	5.5337	9.6588	10.33
Random Forest	100 / 12	5.5333	9.6418	10.88
Random Forest · champion	100 / 18	5.5290	9.6589	15.06

Se seleccionó Random Forest con 100 árboles, profundidad máxima 18, mínimo cinco muestras por hoja y semilla 42. Su MAE de validación (5.5290) representa una reducción del 19.65 % respecto al baseline. En prueba obtuvo MAE 5.6924 y RMSE 9.4911. La configuración de 100 árboles y profundidad 12 tiene un RMSE de validación ligeramente menor y un entrenamiento más rápido (10.88 s frente a 15.06 s), por lo que la elección privilegia MAE, ligado a la estimación diaria de bicicletas demandadas. La diferencia de MAE entre los dos mejores candidatos es pequeña: no debe confundirse con un beneficio operativo medido.

3. P2. Riesgo de vaciado y llenado

Modelo / configuración	AP vaciado ↑	AP llenado ↑	Recall@20 ↑	Precision@20 ↑
Persistencia (baseline)	0.6312	0.6189	0.3615	0.7130
Perfil histórico (baseline)	0.2805	0.3286	0.2314	0.4253
HGB · lr .05 / hojas 31 / balanced	0.7511	0.7525	0.4047	0.7961
HGB · lr .05 / hojas 31 / None	0.7565	0.7586	0.4068	0.7998
HGB · lr .05 / hojas 63 / balanced	0.7545	0.7555	0.4054	0.7977
HGB · lr .05 / hojas 63 / None	0.7591	0.7615	0.4075	0.8014
HGB · lr .10 / hojas 31 / balanced	0.7543	0.7551	0.4046	0.7968
HGB · lr .10 / hojas 31 / None	0.7582	0.7617	0.4070	0.8006
HGB · lr .10 / hojas 63 / balanced	0.7558	0.7573	0.4052	0.7975
HGB · lr .10 / hojas 63 / None · champion	0.7601	0.7623	0.4077	0.8018

La búsqueda anidada de ocho combinaciones favoreció HistGradientBoosting con learning_rate=0.1, max_leaf_nodes=63, max_iter=300, min_samples_leaf=200, L2=1.0, sin ponderación de clases y sin early stopping. Frente a persistencia, Recall@20 subió de 0.3615 a 0.4077 (+4.62 puntos porcentuales; +12.78 % relativo), mientras que los eventos de riesgo cubiertos pasaron de 26,239 a 29,506. La métrica se vincula con la priorización de 20 estaciones; el modelo no representa una medición directa del inventario, pues las etiquetas proceden de una reconstrucción estimada.

La mejora se mantiene en AP, F2 y Brier para vaciado y llenado. Las diferencias entre las configuraciones de mayor rendimiento son estrechas, y no se dispone de tiempos comparables de todas las candidatas para cuantificar el costo de entrenamiento. Los resultados aquí presentados corresponden a validación; las métricas de prueba de P2 no fueron verificadas y se deben indicar como N/D.

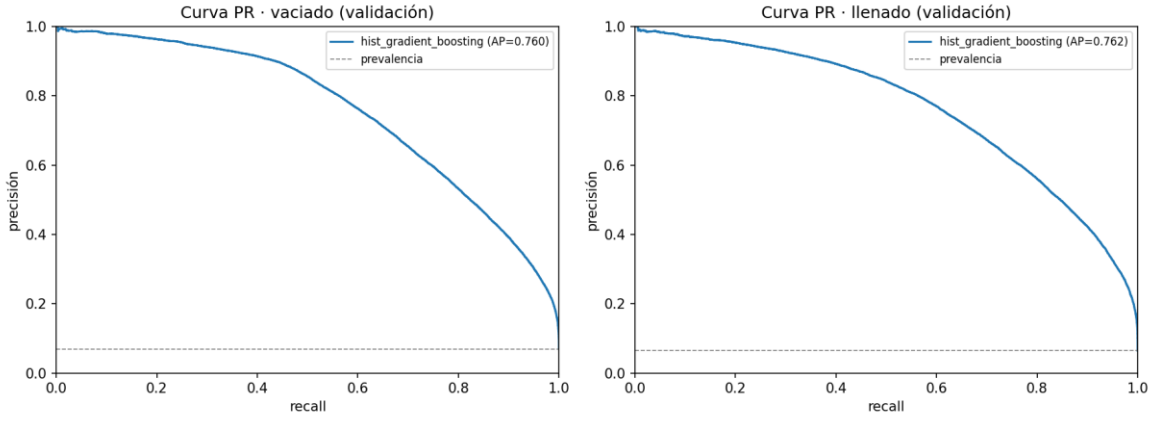


Figura 1. Curvas precisión–recall de validación para vaciado y llenado.

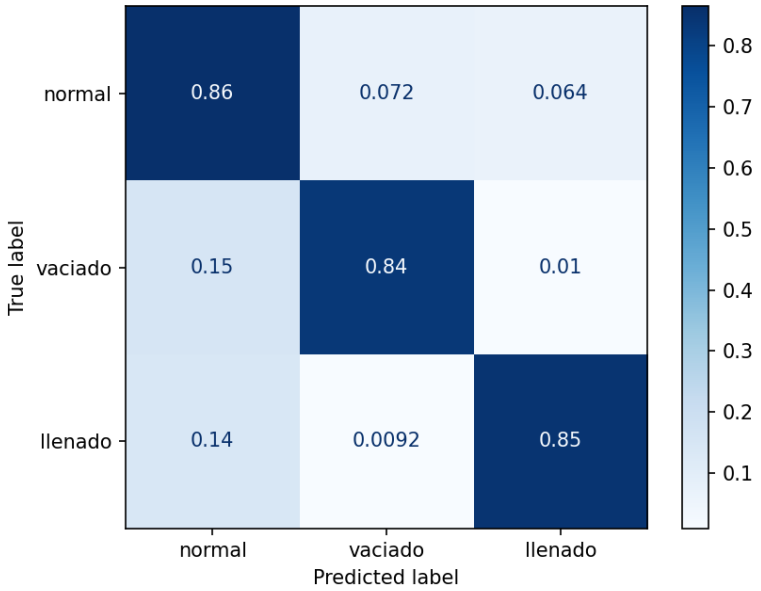


Figura 2. Matriz de confusión de la candidata HistGradientBoosting.

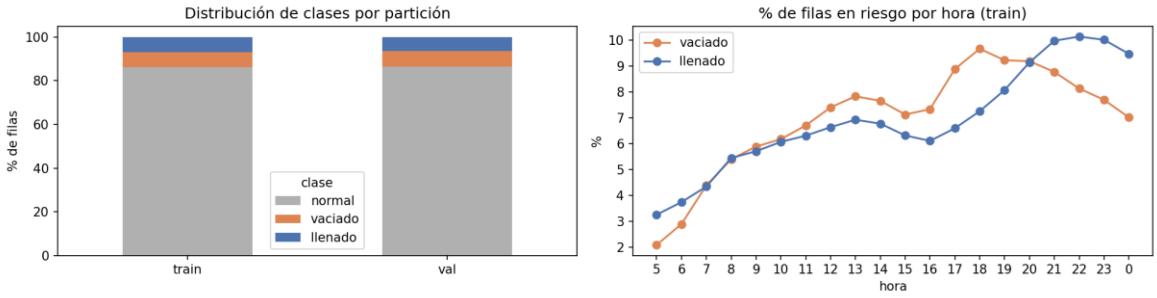


Figura 3. Distribución de clases en entrenamiento y validación y comportamiento horario.

4. P3. Agrupamiento de estaciones

Modelo	Silueta ↑	Davies–Bouldin ↓	ARI vs. Ward ↑	Grupo mínimo
K-Means k=4 · baseline	0.0650	2.7976	0.3576	34
PCA + K-Means k=3 · champion	0.1245	2.2360	0.7196	33

El modelo seleccionado conserva 80 % de la varianza mediante PCA (31 componentes) y produce tres grupos a partir de 372 estaciones y 99 variables originales. El ARI promedio entre semillas fue 0.9417, indicio de estabilidad. Las tres métricas comparables mejoran frente al baseline, aunque la silueta de 0.1245 sigue indicando solapamiento. La interpretación geográfica y operativa requiere validación contextual. La búsqueda completa de 15 combinaciones se presenta en la tabla siguiente.

No se presentan métricas de test supervisadas para P3 porque se trata de una tarea no supervisada; esta decisión metodológica debe explicarse, no sustituirse por resultados inventados.

4.1 . Búsqueda completa de 15 configuraciones de P3

La búsqueda combinó varianza PCA de 80 %, 90 % y 95 % con k entre 3 y 7. La tabla incluye todas las combinaciones registradas; el puntaje es el valor compuesto guardado por MLflow, no una métrica de prueba.

PCA	k	Silueta ↑	Davies–Bouldin ↓	ARI Ward ↑	Puntaje
80%	3	0.1245	2.2360	0.7196	1.9978
80%	4	0.0656	2.7886	0.3810	-0.6364
80%	5	0.0647	2.6485	0.3776	-0.4189
80%	6	0.0600	2.7422	0.4235	-0.5364
80%	7	0.0622	2.5067	0.4154	-0.1217
90%	3	0.1247	2.2431	0.7110	1.9666
90%	4	0.0608	2.8223	0.3770	-0.7753
90%	5	0.0675	2.6345	0.3706	-0.3710
90%	6	0.0574	2.7430	0.3297	-0.8047
90%	7	0.0612	2.5605	0.3100	-0.4855
95%	3	0.1239	2.2445	0.7109	1.9526
95%	4	0.0647	2.8111	0.3932	-0.6593
95%	5	0.0626	2.7259	0.4082	-0.5078
95%	6	0.0664	2.7582	0.4568	-0.3885
95%	7	0.0566	2.5193	0.4814	-0.0646

El candidato PCA 80 % y k=3 obtuvo el mayor puntaje compuesto (1.9978), el mejor Davies–Bouldin (2.2360) y el mayor ARI frente a Ward (0.7196) entre las configuraciones de k=3. La silueta más alta fue la de PCA 90 % y k=3 (0.1247), una diferencia marginal respecto al ganador (0.1245). La selección equilibra criterios y estabilidad entre semillas (ARI medio 0.9417); no demuestra grupos claramente separados.

5. Model Registry y ciclo de vida

Pregunta	Nombre registrado	Versión	Alias	Run de origen
P1	mibici-equipo37-p1-demanda	1	champion	149ddb98…
P2	mibici-equipo37-p2-riesgo	1	champion	acdae4e1…
P3	mibici-equipo37-p3-grupos	1	champion	c6c2daa8…

Los tres modelos incluyen descripción y etiquetas de linaje que identifican experimento, corrida, commit y versión de datos. El alias champion se utiliza como referencia estable de la versión elegida para consumo; challenger es opcional y no se encontró asignado en la base compartida. Frente al esquema clásico de etapas, los alias permiten redirigir el consumo a una versión sin modificar el URI de la aplicación.

```
mlflow.pyfunc.load_model("models:/mibici-equipo37-p1-demanda@champion")
mlflow.pyfunc.load_model("models:/mibici-equipo37-p2-riesgo@champion")
mlflow.pyfunc.load_model("models:/mibici-equipo37-p3-grupos@champion")
```

Se verificó en Terminal la carga de los tres modelos por nombre y alias. La carga exitosa no equivale a demostrar predicciones correctas en producción; no se ejecutó una prueba de predicción con ejemplos de entrada durante esta revisión.

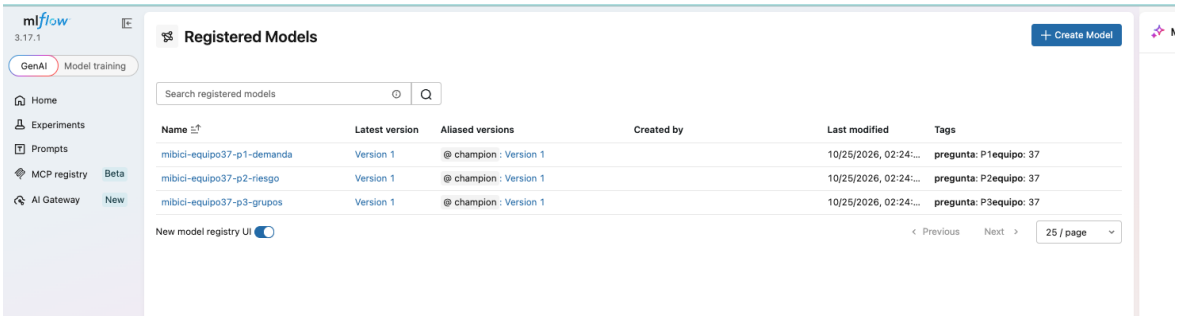


Figura 4. Tres modelos registrados con alias champion.

6. Evidencias de experimentación, artefactos y linaje

Las corridas de búsqueda muestran relaciones padre–hija. Para P2, la corrida padre conserva la selección y las hijas contienen las combinaciones de hiperparámetros. La candidata final guarda manifiesto, configuración y gráficos en data/, config/, plots/ y results/. En MLflow 3, los modelos serializados aparecen en Logged models, no necesariamente como una carpeta en Artifacts. Se identificaron firmas y ejemplos de entrada en los metadatos de modelos, aunque queda pendiente una comprobación exhaustiva por corrida candidata.

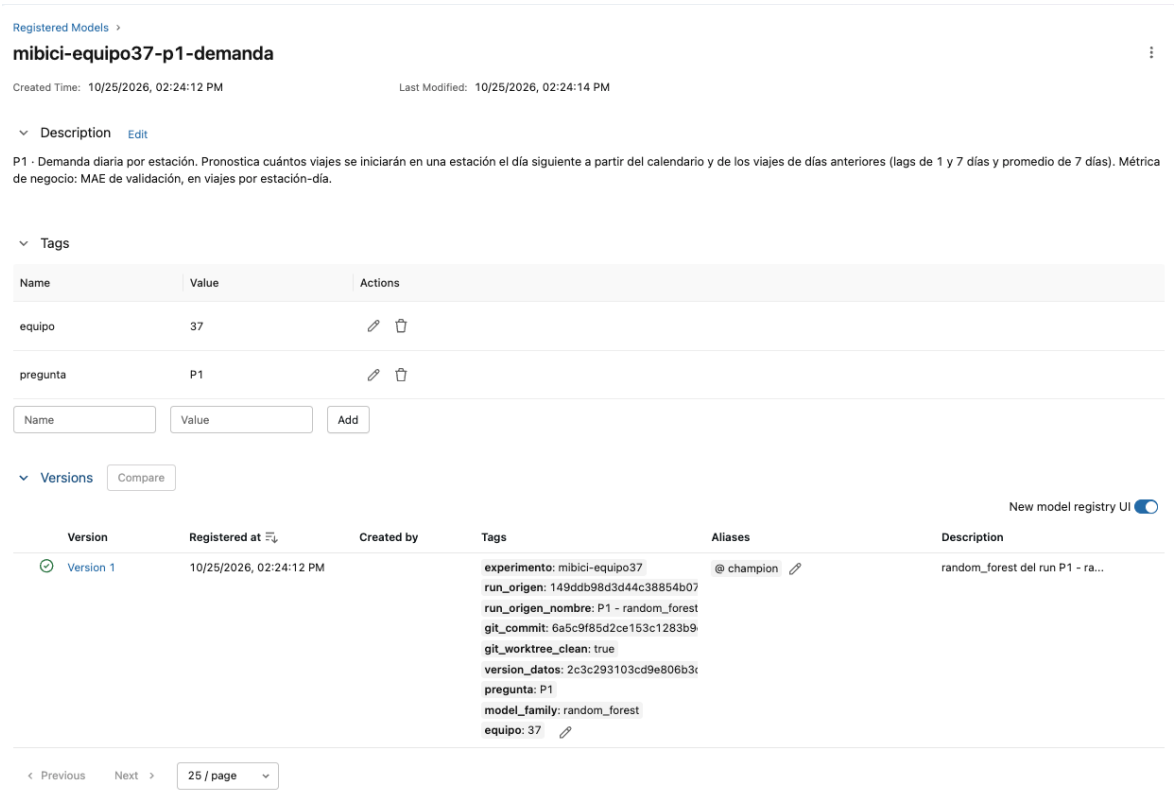


Figura 5. P1: descripción y etiquetas de linaje de la versión registrada.

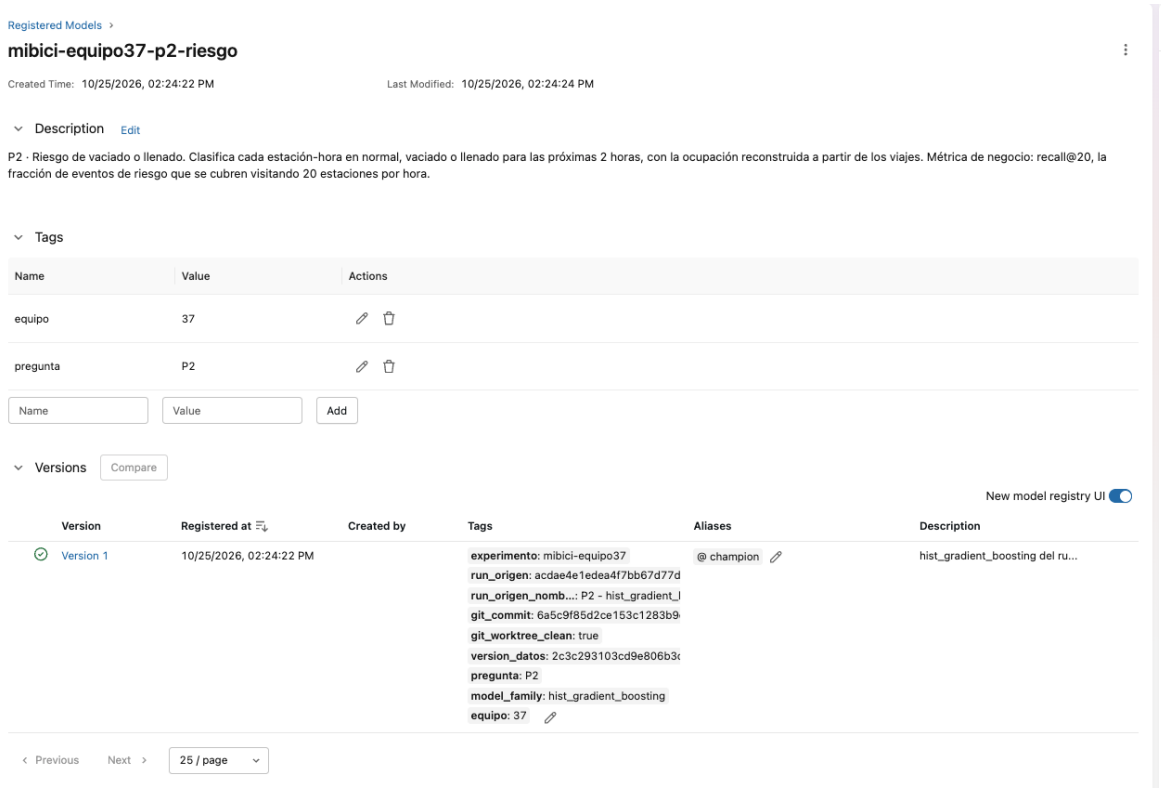


Figura 6. P2: descripción y etiquetas de linaje de la versión registrada.

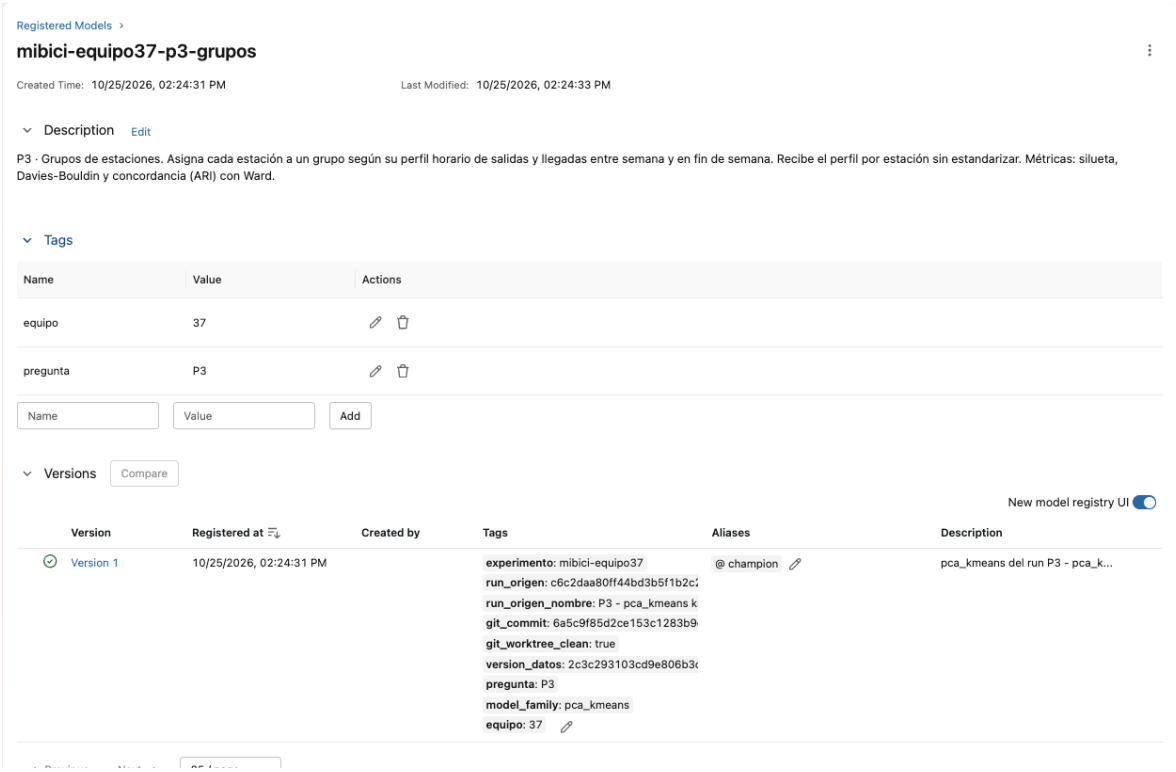


Figura 7. P3: descripción y etiquetas de linaje de la versión registrada.



Figura 8. Ejemplo de búsqueda con nested runs en P2.

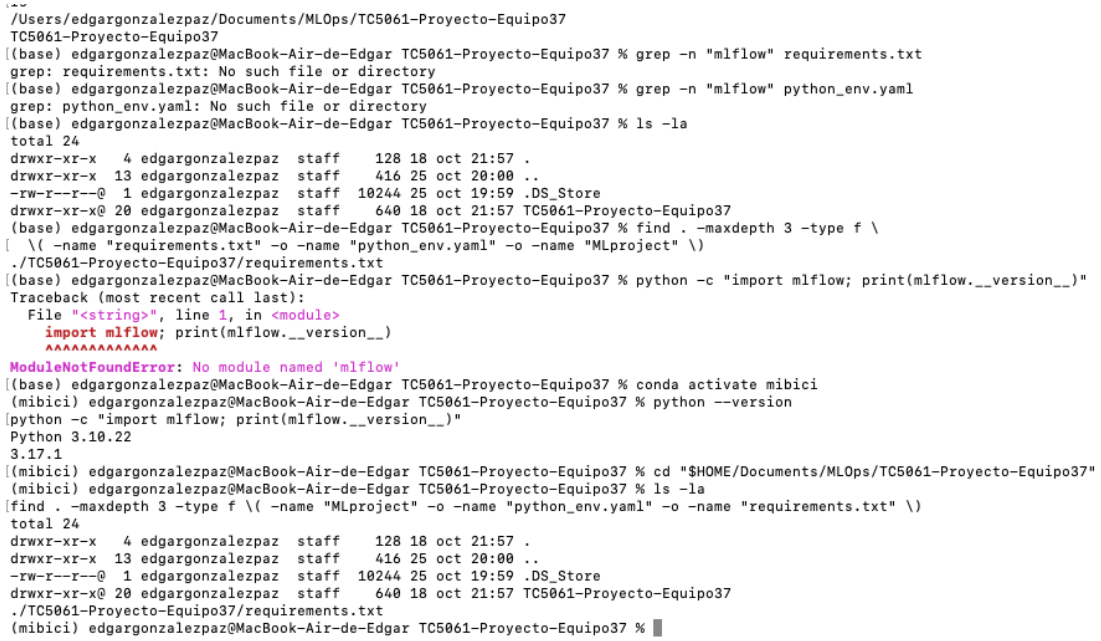


Figura 9. Árbol de artefactos de la corrida candidata P2.

7. Alcance de la comprobación y limitaciones

Aspecto	Resultado y limitación
Clon limpio	Se verificó instalación, ingesta y ejecución de P1, P2 y P3 en entorno independiente.
Reproducción de ganadores	P1 coincidió; P2 y P3 finalizaron usando hiperparámetros predeterminados, por lo que no se demostró reproducción exacta de ambos champion.
Prueba de P2	No se verificaron métricas de test; las cifras informadas son de validación.
Artefactos y firmas	Se revisaron artefactos principales y se cargaron los tres modelos por alias; no se auditó exhaustivamente cada corrida candidata.
Documentación del proyecto	El README recibido conservaba marcadores de ganadores pendientes y comandos con hiperparámetros no declarados en MLproject.

La evaluación distingue entre ejecución satisfactoria del flujo y reproducción exacta de una configuración ganadora. No se atribuyen resultados de prueba no observados ni se afirma un despliegue productivo externo: champion representa el alias de la versión seleccionada en el registro local.

8. Conclusiones

La experimentación centralizada permite comparar tres decisiones distintas: anticipar demanda con MAE, priorizar estaciones en riesgo con Recall@20 y caracterizar patrones de uso con métricas internas y estabilidad. La trazabilidad mediante corridas, commits y versiones de datos, junto con el registro por alias champion, facilita auditoría y consumo consistente. La reproducibilidad de extremo a extremo requiere todavía demostrar ejecución desde un clon limpio y cerrar las discrepancias documentales. Estas precauciones son coherentes con las prácticas de empaquetado y seguimiento de modelos descritas por Treveil et al. (2020) y Lakshmanan et al. (2020).

9. Referencias (APA 7)

Lakshmanan, V., Robinson, S., & Munn, M. (2020). Machine learning design patterns: Solutions to common challenges in data preparation, model building, and MLOps. O'Reilly Media.

MLflow. (s. f.-a). MLflow Model Registry [Documentación]. https://mlflow.org/docs/latest/ml/model-registry/

MLflow. (s. f.-b). MLflow Projects [Documentación]. https://mlflow.org/docs/latest/ml/projects/

MLflow. (s. f.-c). MLflow Tracking [Documentación]. https://mlflow.org/docs/latest/ml/tracking/

Treveil, M., Omont, N., Stenac, C., Lefevre, K., Phan, D., Zentici, J., Lavoillotte, A., Miyazaki, M., & Heidmann, L. (2020). Introducing MLOps: How to scale machine learning in the enterprise. O'Reilly Media.